

Antonius Valentino

Business Intelligence · Data Analyst

Fresh graduate Sistem Informasi yang tertarik membangun sistem berbasis data; dari pipeline analitik dan KPI layer hingga model ML yang dapat dijelaskan. Kumpulan Project berikut menggambarkan bagaimana saya mendekati masalah bisnis nyata dengan pendekatan teknis yang terukur.

CORE STACK

Python

XGBoost · LightGBM

SHAP

Streamlit

Pandas · NumPy

Scikit-learn

Optuna

MySQL

Next.js

Ollama · Gemma 3

FOKUS DOMAIN

Credit Risk Modelling

Sports Analytics

Full-stack Development

Explainable AI

Technology follows the problem

Saya memandang data sebagai alat untuk memahami kondisi bisnis dan mendukung pengambilan keputusan yang lebih baik. Karena itu, setiap proyek dalam Dokumen Studi Kasus ini dimulai dari kebutuhan dan permasalahan nyata yang dihadapi pengguna atau organisasi, bukan semata-mata dari ketertarikan terhadap teknologi tertentu.

PENDEKATAN KERJA

Data leakage prevention

Setiap pipeline dirancang dengan pemisahan yang ketat: scaler di-fit di data train, transform di val/test, dan SMOTE hanya diterapkan di train. Ini bukan sekadar best practice, melainkan cara memastikan metrik yang dilaporkan mencerminkan performa model di data yang belum pernah dilihat sebelumnya.

Explainability sebagai fitur utama

Dari SHAP force plots hingga Model Integrity page, setiap keputusan model harus bisa dijelaskan kepada loan officer, analis klub, maupun pemilik bisnis laundry.

Business metric di atas model metric

AUC 0.86 baru bermakna ketika diterjemahkan ke sesuatu yang konkret: berapa banyak default yang berhasil dideteksi, berapa jam kerja manual yang bisa dikurangi, atau seperti apa dampaknya terhadap keputusan bisnis sehari-hari.

KOMPETENSI TEKNIS

AREA	TOOLS & TEKNIK	LEVEL
ML / Modeling	XGBoost, LightGBM, Scikit-learn, Optuna, SMOTE	
Explainability	SHAP (TreeExplainer, force plots, summary plots)	
Data Engineering	Pandas, NumPy, Feature Engineering, Time-series split	
Visualisasi & App	Streamlit, Plotly, Matplotlib	
Database & Backend	MySQL, Next.js API Routes, Prepared Statements	
Business Analysis	KPI design, business metric interpretation, domain research	

PENDIDIKAN

S1 Sistem Informasi
Telkom University · 2021–2026

Tiga project, tiga domain berbeda

Setiap project dibangun dari nol — dari eksplorasi data hingga deployment sebagai aplikasi interaktif atau sistem produksi.

01

Predictive Credit Scoring untuk UMKM Indonesia

Fintech · Credit Risk · Explainable AI

XGBOOST

SHAP

STREAMLIT

OPTUNA

PROBLEM

Evaluasi kredit UMKM yang manual, lambat, dan tidak konsisten. Tidak ada sistem yang menjelaskan *mengapa* peminjam ditolak.

SOLUSI

Pipeline ML end-to-end: EDA, Feature Engineering, XGBoost, Optuna, SHAP, hingga Streamlit app dengan fitur threshold override.

KEY METRICS

86.4%

AUC-ROC

55%

DEFAULT DETECTED

<1s

DECISION TIME

02

xFlair — Prediksi Nutmeg di Piala Dunia 2026

Sports Analytics · Predictive Modelling · StatsBomb

XGBOOST

STATSBOMBPY

SHAP

PLOTLY

PROBLEM

Tidak ada sistem yang mengukur *flair* dan kreativitas pemain sepakbola secara kuantitatif dari data event.

SOLUSI

Pipeline time-series dari 522K events StatsBomb, dengan Player-Match formulation untuk menghindari mathematical tautology.

KEY METRICS

27.9%

MAE IMPROVEMENT

522K

EVENTS DIPROSES

0

DATA LEAKAGE

03

WHSER — Laundry Management Platform

Full-stack · Business Intelligence · LLM Integration

NEXT.JS

MYSQL

SELF-HOSTED LLM

TYPESCRIPT

PROBLEM

Operasi laundry volume tinggi yang tidak terstruktur: order mudah terlewat, SLA sering dilanggar, dan tidak ada visibilitas atas profitabilitas per layanan.

SOLUSI

Dual-layer architecture: lapisan operasional (POS real-time) + lapisan analitik (snapshot imutabel + 8 KPI + LLM insight).

KEY METRICS

20

DATABASE TABLES

8

KPI DIHITUNG

Est. 30h

SAVED/WEEK

PROBLEM STATEMENT

Bank dan fintech yang melayani UMKM Indonesia menghadapi dilema yang cukup mendasar: proses evaluasi kredit yang manual bisa memakan waktu 30–60 menit per pengajuan, hasilnya tidak konsisten antar loan officer, dan tidak ada penjelasan yang bisa diberikan kepada nasabah ketika pengajuan mereka ditolak. Akibatnya, dua masalah muncul bersamaan: peminjam berisiko yang lolos seleksi, dan peminjam layak yang justru ditolak.

Tantangan inti bukan sekadar membuat model akurat, melainkan **mengoptimalkan threshold keputusan** — batas antara "setujui" dan "tolak" yang mencerminkan appetite risiko bisnis, bukan hanya metrik statistik.

BUSINESS IMPACT

86.4%

AUC-ROC TEST SET

55%

DEFAULT TERDETEKSI


<1s

DECISION TIME

\$374k

ESTIMASI SAVINGS/YEAR

PIPELINE END-TO-END



YANG MEMBEDAKAN PROJECT INI

Threshold sebagai Policy Artifact

Threshold 0.5354 disimpan sebagai file JSON terpisah, di-version control, dan bisa di-override dari UI, tanpa retrain model.

Zero Data Leakage by Design

RobustScaler hanya di-fit di train set. SMOTE hanya di train set. Val/test mencerminkan distribusi produksi yang sesungguhnya.

Explainability Wajib, Bukan Opsional

Setiap keputusan kredit disertai SHAP force plot. Loan officer bisa membaca alasan spesifik: "2 kejadian tunggakan 90 hari mendorong skor ke arah default."

Keputusan teknis kritis dan alasannya

01 — RobustScaler vs StandardScaler

DATA PREP

Masalah: Data memiliki outlier ekstrem (income hingga \$3.8M, utilization >1.5). StandardScaler menggunakan mean/std yang sensitif terhadap outlier.

Keputusan: RobustScaler menggunakan median dan IQR, sehingga lebih tahan terhadap outlier tanpa mengorbankan interpretabilitas transformasi linear.

02 — Stratified Split (60/20/20)

VALIDATION

Masalah: Target class imbalanced (93.2% good, 6.8% default). Random split berisiko menghasilkan distribusi yang tidak seragam.

Keputusan: `train_test_split(..., stratify=y)` memastikan setiap split memiliki ~6.8% default, menghasilkan metrik yang dapat diperbandingkan.

03 — SMOTE hanya di Train Set

IMBALANCE

Masalah: Menerapkan SMOTE sebelum split menyebabkan data leakage — synthetic samples dari minoritas akan "bocor" ke validation set.

Keputusan: SMOTE hanya di-fit dan di-transform pada training set. Val/test tetap mencerminkan distribusi produksi yang imbalanced.

04 — Threshold Tuning via F1 Max

BUSINESS LOGIC

Masalah: Threshold 0.5 adalah angka arbitrer yang tidak mencerminkan biaya asimetris: FN (approve default) jauh lebih mahal dari FP (tolak peminjam baik).

Keputusan: Sweep threshold di validation set, pilih yang memaksimalkan F1-minority. Hasil: threshold 0.5354, disimpan sebagai `best_threshold.json`.

05 — SHAP vs LIME

EXPLAINABILITY

Masalah: Loan officer dan regulator membutuhkan penjelasan yang dapat dipertanggungjawabkan, termasuk untuk keperluan audit atau kepatuhan regulasi.

Keputusan: SHAP menggunakan Shapley values dari game theory — teoritis lebih kuat dari LIME. Mendukung penjelasan lokal (per peminjam) dan global (feature importance seluruh dataset).

PERBANDINGAN MODEL

MODEL	AUC-ROC	F1-MINORITY	STATUS
XGBoost (Tuned)	0.8641	0.4421	Dipilih
LightGBM	0.8503	0.3735	+1.4% AUC tapi -15.7% F1-minority
Logistic Regression	0.8475	0.3184	Baseline

XGBoost dipilih bukan karena AUC tertinggi, melainkan karena **F1-minority 38% lebih tinggi dari LightGBM**. Dalam credit risk, mendeteksi default adalah prioritas bisnis utama, bukan kecepatan inference.

OPTUNA HYPERPARAMETER TUNING

PARAMETER	BEST VALUE	SEARCH RANGE
n_estimators	350	100–500
max_depth	5	3–8
learning_rate	0.08	0.01–0.3
scale_pos_weight	3.2	1–5

ARTIFACT YANG DIPERSIST

best_xgb_model.json

— XGBoost model serialized

scaler.pkl


— RobustScaler untuk inference

best_threshold.json


— Decision boundary (0.5354)

Setiap keputusan kredit harus bisa dijelaskan

SHAP FEATURE IMPORTANCE (GLOBAL)



SHAP FORCE PLOT — CONTOH PEMINJAM (LOCAL)



THRESHOLD SEBAGAI POLICY INSTRUMENT

Threshold adalah keputusan bisnis. Dengan menyimpannya sebagai artifact terpisah, lending team dapat melakukan simulasi kebijakan tanpa menyentuh kode model.

THRESHOLD	APPROVAL RATE	EST. DEFAULT RATE	STRATEGI
0.30	~40%	<2%	Ultra-konservatif
0.5354	~70%	~5-6%	Balanced (tuned)
0.70	~95%	~15%	Inklusif tinggi

FEATURE ENGINEERING — BUSINESS RATIONALE

- weighted_late_score**

$late_{30} \times 1 + late_{60} \times 2 + late_{90} \times 4$ - Tunggakan 90 hari adalah sinyal charge-off (standar industri perbankan). Bobot 4x mencerminkan keseriusan yang berbeda.
- income_per_dependent**

Pendapatan 5 juta dengan 4 tanggungan berbeda maknanya dengan 5 juta tanpa tanggungan. Feature ini menangkap tekanan finansial keluarga yang tidak terlihat dari angka pendapatan mentah saja.
- dti_adjusted**

Debt-to-income ratio adalah standar regulasi perbankan (batas aman 30-40%), sehingga feature ini membuat model "berbicara bahasa" yang sama dengan risk manager.

Apa yang saya pelajari dan apa batasannya

PEMBELAJARAN KRITIS

1. "Hasil sempurna" adalah red flag

Di iterasi awal, MAE model hampir nol. Saya skeptis, mengulang proses, dan menemukan bahwa target variabel dapat diturunkan secara matematis dari dua feature (tautology). Ini mengajarkan saya bahwa validation yang jujur lebih penting dari metrik yang impressive.

2. Threshold adalah keputusan bisnis, bukan pilihan teknis

Saya awalnya menggunakan threshold 0.5 secara default. Setelah memahami konteks bisnis kredit UMKM lebih dalam, saya menyadari bahwa threshold yang tepat harus mencerminkan biaya asimetris antara FN dan FP, dan harus bisa disesuaikan tanpa perlu retraining.

3. Feature engineering dari domain knowledge > dari korelasi statistik

Menambahkan `weighted_late_score` (yang lahir dari pemahaman bahwa tunggakan 90 hari adalah batas charge-off di perbankan) memberikan improvement yang lebih bermakna dibandingkan feature engineering berbasis korelasi semata.

PROJECT SUMMARY

"Developed explainable credit risk model (86.4% AUC-ROC) with interactive policy dashboard; detected 55% of defaults pre-approval through XGBoost + SHAP pipeline with zero data leakage; operationalized decision threshold as version-controlled artifact enabling risk appetite simulation without model retraining."

DESIGN DECISION

Trade-off yang menentukan pilihan model:

"Di project ini, saya memilih XGBoost bukan karena AUC-nya tertinggi, melainkan karena F1-minority-nya 38% lebih baik dari LightGBM. Dalam credit scoring, model yang melewati default adalah model yang gagal secara bisnis, meski AUC-nya sempurna."

Insight ini datang dari memahami bahwa biaya false negative, yaitu menyetujui peminjam yang kemudian gagal bayar, jauh lebih besar dari biaya false positive, yaitu menolak peminjam yang sebenarnya layak. Itulah mengapa threshold juga saya simpan sebagai artifact terpisah yang bisa disesuaikan oleh lending team tanpa perlu memanggil data scientist."

LINK

GitHub: github.com/val-Antonius/predictive_credit_scoring_for_umkm

Demo App: shap-credit-scoring.streamlit.app

KETERBATASAN YANG DIAKUI

- **Data dari 2009** (krisis finansial) — tingkat default mungkin tidak merepresentasikan kondisi UMKM Indonesia saat ini.
- **Recall hanya 55%** — ~45% default lolos dari prediksi. Model perlu dikombinasikan dengan review manual untuk kasus borderline.
- **Fairness audit belum dilakukan** — age sebagai feature berpotensi menjadi proxy diskriminasi. Audit disparate impact diperlukan sebelum deployment produksi.

PROBLEM STATEMENT

Nutmeg — melewati bola di antara kaki lawan, bukan skill move tingkat tinggi — semua pemain bisa melakukannya. Tapi hanya sebagian kecil yang memilih melakukannya dalam tekanan pertandingan. Itulah yang membuatnya menarik: ia bukan indikator performa, melainkan sinyal *keberanian* dan *flair* yang murni bersifat hiburan.

Media olahraga, platform fantasy sports, dan industri broadcast tidak punya cara sistematis untuk mengukur ini. Pertanyaan project ini adalah **dapatkah kita memprediksi berapa kali seorang pemain akan melakukan nutmeg sebelum pertandingan dimulai?**

BUSINESS VALUE

522K
EVENTS DIPROSES

27.9%
MAE IMPROVEMENT

Use case: fan engagement & broadcast

Pemain dengan predicted nutmeg rate tinggi adalah konten yang menjual — untuk pre-match narrative, fantasy sports, atau exotic bet market.

PIPELINE ARSITEKTUR



Kenapa Nutmeg?

Justru karena nutmeg bukan indikator performa, ia menjadi proxy flair yang menarik; murni tentang keberanian dan kreativitas dalam momen 1v1. Dan dari sudut pandang analitik, memprediksi event yang "tidak perlu tapi dipilih" jauh lebih sulit dari memprediksi event yang memang direncanakan.

Model Integrity Page

Tidak banyak portfolio yang secara transparan menampilkan keterbatasan modelnya. xFlair memiliki halaman khusus untuk decile calibration chart dan error analysis — membangun kepercayaan, bukan menyembunyikan kelemahan.

Target Audience

Analisis media olahraga, platform fantasy sports, dan industri broadcast. Nutmeg adalah entertainment event, dan project ini mencoba mengukur sesuatu yang selama ini hanya hidup di highlight reel.

Menemukan & menyelesaikan Mathematical Tautology

THE TAUTOLOGY PROBLEM

Iterasi Pertama — Terlihat Berhasil

Model pertama dengan agregasi Player-level menghasilkan MAE yang sangat rendah. Prediksi terlihat sempurna; semua pemain mendapat nilai sekitar 0.71.

Ini adalah red flag. Setelah investigasi, ditemukan bahwa target variabel dapat diturunkan secara matematis dari dua feature:

$$y = \text{nutmegs} / \text{total_dribbles} = f(\text{feature_1} / \text{feature_2})$$

Model tidak belajar pola — ia hanya melakukan aritmatika. Ini adalah Mathematical Tautology.

FEATURES YANG DIGUNAKAN

FEATURE	DESKRIPSI	SUMBER
career_nutmeg_rate	Nutmeg / total dribble historis	Rolling
rolling_nutmeg_rate_last5	Rata-rata 5 match terakhir	shift(1)
rolling_dribbles_last5	Exposure / kesempatan masa lalu	shift(1)
opponent_duel_win_rate	Kekuatan defensif lawan	StatsBomb
career_dribble_success	Skill dribbling umum	Agregasi
match_number	Pengalaman di turnamen ini	Derived

HASIL MODEL

0.306

MAE (MODEL)

0.424

MAE (BASELINE)

27.9%

IMPROVEMENT

TIME-SERIES SPLIT — INTEGRITAS METODOLOGI

Random split dilarang untuk data time-series. Membocorkan data masa depan ke training adalah salah satu bentuk data leakage paling berbahaya.

Train Set
≤ 30 Juni 2024

→

Test Set
1–15 Jul 2024

Design Decision

"Hasil yang terlalu bagus adalah tanda bahaya, bukan keberhasilan. Hasil yang sempurna harus diselidiki lebih dalam, bukan langsung dirayakan."

REDESIGN: PLAYER-MATCH FORMULATION

SEBELUM (PLAYER-LEVEL)

Setiap baris = satu pemain
Target = nutmeg rate karir
Feature = statistik karir
Masalah: $y = f(x_1/x_2)$



SESUDAH (PLAYER-MATCH)

Setiap baris = satu pertandingan
Target = nutmeg di match T
Feature = data sebelum match T
Solusi: Prediksi masa depan dari masa lalu

SHIFT(1) — TIME-SERIES INTEGRITY

Rolling features menggunakan `shift(1)` — setiap baris hanya menggunakan informasi dari pertandingan sebelumnya, bukan pertandingan yang sedang diprediksi.

```
rolling_nutmeg_rate_last5 = shift(1).rolling(5).mean()
```

Match pertama tiap pemain: rolling feature = 0 (tidak ada history sebelumnya). Ini jujur secara metodologis.

The Flair Index – dari data event ke prediksi per pemain

THE FLAIR INDEX — TOP PLAYER RANKING

EXPECTED NUTMEG / MATCH · WC 2026 PREDICTION

Neymar Jr.	0.87 predicted
Richarlison	0.72 predicted
Vinícius Jr.	0.65 predicted
Mbappé	0.58 predicted
Salah	0.43 predicted

*Nama pemain adalah ilustrasi untuk demonstrasi format

MODEL INTEGRITY – TRANSPARANSI AKTIF

Diferensiator Utama Project Ini

Halaman Model Integrity secara eksplisit menampilkan:

1. Decile calibration chart (predicted vs actual)
2. Error analysis per pemain
3. Keterbatasan dataset (hanya 3 turnamen)

"Transparansi membangun kepercayaan yang tidak bisa dibangun dengan accuracy tinggi sekalipun."

PROJECT SUMMARY

"Built end-to-end sports analytics ML pipeline predicting nutmeg frequency for WC 2026 flair players using XGBoost on 522,885 StatsBomb events; achieved 27.9% MAE improvement over baseline with zero data leakage via Player-Match time-series formulation."

KEY LEARNINGS

Granularitas data menentukan validitas model

Player-level aggregation terlihat lebih simpel, tapi menghasilkan tautology. Player-Match formulation lebih kompleks, tapi satu-satunya cara yang valid secara metodologis untuk prediksi time-series.

Dataset kecil bukan hambatan, tapi tantangan desain

664 rows adalah dataset yang sangat kecil untuk ML. Solusinya bukan lebih banyak data (data terbatas), melainkan regularisasi lebih ketat dan feature yang lebih informatif.

Keterbatasan yang diakui membangun kepercayaan yang lebih besar

Model Integrity page justru membuat project ini lebih meyakinkan. Menampilkan kelemahan secara terbuka menunjukkan bahwa saya memahami batas kemampuan model, bukan hanya cara membangunnya.

KETERBATASAN & PENGEMBANGAN

- Saat ini hanya mencakup 3 turnamen internasional; data liga domestik belum digunakan
- Pemain tanpa history di 3 kompetisi ini belum dapat diprediksi
- Dataset 664 baris (sedang dikembangkan dengan menambah cakupan data untuk memvalidasi hasil lebih lanjut)

LINK

GitHub: github.com/val-Antonius/xflairDemo App: xflair.streamlit.app

PROBLEM STATEMENT

Bisnis laundry volume tinggi mengandalkan spreadsheet, catatan tangan, dan panggilan telepon. Akibatnya: order hilang, SLA dilanggar tanpa deteksi dini, inventaris salah kelola, dan pemilik tidak memiliki visibilitas profitabilitas per jenis layanan.

WHSER mengubah operasi laundry dari alur kerja manual yang tidak terstruktur menjadi proaktif melalui **arsitektur dual-layer**: lapisan operasional untuk staff sehari-hari, dan lapisan analitik untuk keputusan strategis pemilik.

BUSINESS IMPACT

100%

ORDER TRACKED

30h

SAVED / WEEK


20

DATABASE TABLES

50+

API ENDPOINTS

DUAL-LAYER ARCHITECTURE



Order sebagai Single Source of Truth

Semua data (items, status history, exceptions, inventory consumption) terhubung ke satu entitas: tabel orders. Setiap perubahan status tercatat di order_status_log secara imutabel.

Snapshot Imutabel untuk Finansial

Data analitik di-freeze pada batas periode, sehingga laporan Januari tidak akan berubah meski data diperbarui di Februari. Ini penting untuk konsistensi audit keuangan dan pengambilan keputusan historis.

LLM sebagai Augmentasi, Bukan Otomatisasi

Rekomendasi dari Gemma 3 membutuhkan persetujuan pemilik sebelum dieksekusi. Pendekatan human-in-the-loop ini memastikan keputusan bisnis tetap berada di tangan yang tepat.

Dari event transaksi ke keputusan strategis

PIPELINE: RAW DATA → ACTIONABLE INSIGHT



8 KPI YANG DIHITUNG

KPI	FORMULA SINGKAT	TARGET	SIGNIFIKANSI
SLA Compliance	on_time / total_completed	>95%	Normal
Rewash Rate	rewashes / completed	<5%	Attention
Exception Freq.	exceptions / total orders	<2%	Critical
Contribution Margin	revenue – material – labor	>70%	Normal
Inventory Variance	(actual – expected) / expected	<10%	Attention
Aging Distribution	count(>72h) / total	<10%	Normal
Productivity	completed / days_in_period	Baseline	Normal
Capacity Utilization	peak_concurrent / capacity	60–80%	Normal

KEPUTUSAN TEKNIS KRITIS

- Pemisahan Operasional & Analitik**

Query analitik yang berjalan pada data live menyebabkan lock contention di database dan memperlambat transaksi. Snapshot memisahkan beban ini: transaksi tetap cepat, analitik tidak bersaing dengan POS.
- Snapshot Manual, Bukan Otomatis**

Pemilik memutuskan kapan menganalisis (mingguan, bulanan, atau ad-hoc). Snapshot otomatis akan menciptakan terlalu banyak data yang tidak digunakan. Agency ada di tangan pemilik bisnis.
- MySQL Tanpa ORM**

Prepared statements langsung memberikan kontrol penuh atas query, performa lebih baik untuk prototype, dan secara built-in mencegah SQL injection. ORM menambah abstraksi yang tidak diperlukan di fase ini.
- Role-Based Dual Dashboard**

Admin melihat workflow real-time. Owner melihat trend strategis. Satu dashboard yang mencoba melayani keduanya dapat menciptakan cognitive overload, sehingga dua dashboard dengan dua konteks yang berbeda adalah pilihan yang lebih tepat

TECH STACK

NEXT.JS 14

TYPESCRIPT

MYSQL

OLLAMA

GEMMA 3 4B

JSPDF

REACT

Systems thinking di balik setiap keputusan desain

LLM INTEGRATION — DETAIL IMPLEMENTASI

Human-in-the-Loop Pipeline

- 1 Pemilik mencatat insight dari dashboard KPI (interpretasi human, bukan otomatis)
- 2 Gemma 3 membaca insight + metrics → generate rekomendasi operasional spesifik
- 3 Pemilik review & approve rekomendasi yang relevan (human gate)
- 4 Tasks dibuat dan di-assign ke staff — efektivitas diukur di snapshot berikutnya

PEMBELAJARAN KRITIS

- Arsitektur yang baik menyelesaikan masalah bisnis sebelum masalah teknis
- Pemisahan operational dan analytical layer lahir dari pemahaman bahwa pemilik dan staff memiliki kebutuhan informasi yang fundamental berbeda, bukan dari preference teknis.
- Imutabilitas adalah fitur, bukan keterbatasan
- Snapshot yang tidak bisa diubah terlihat seperti keterbatasan di awal. Tapi untuk konteks audit keuangan dan pertanggungjawaban keputusan, imutabilitas adalah requirement, bukan trade-off.
- Manual-first adalah pilihan, bukan kekurangan
- Konsumsi inventaris diinput manual oleh staff, bukan sensor IoT. Ini bukan keterbatasan anggaran, melainkan keputusan desain: sistem harus deployable hari ini, di laundry mana pun, tanpa hardware khusus.

PROJECT SUMMARY

"Architected dual-layer laundry management system separating operational (real-time POS) from analytical (immutable snapshot-based analytics) concerns; computed 8 business KPIs with baseline comparison and significance detection; integrated local LLM (Gemma 3) for human-approved operational recommendations."

DECISION DESIGN

Memilih solusi yang tepat, bukan yang paling kompleks:

"Saya sempat mempertimbangkan real-time analytics dengan streaming data. Secara teknis lebih impressive. Tapi setelah memahami kebutuhan bisnis, pemilik laundry tidak butuh data real-time setiap detik. Snapshot imutabel adalah jawaban yang benar."

STATUS PENGEMBANGAN

Phase 1: Operational App	Selesai
Phase 2: Role-based Dashboards	Selesai
Phase 3: Analytics & Snapshots	Selesai
Phase 4: LLM Integration	Selesai
Phase 5: Task Management	Selesai

LINK

GitHub: github.com/val-Antonius/whser

TERIMA KASIH TELAH MEMBACA.

Saya antusias mendiskusikan *project ini lebih dalam*

Ketiga project di atas mencerminkan bagaimana saya mendekati masalah:
memulai dari pertanyaan bisnis, merancang solusi yang dapat dijelaskan, dan
memastikan keputusan teknis selalu dapat dipertanggungjawabkan.

EMAIL

thonybo6661@gmail.com

LINKEDIN

linkedin.com/in/antonius-valentino

GITHUB

github.com/val-Antonius

PORTFOLIO WEB

valantonius.me